


Laboratorio de Datos



Aprendizaje Automático




DEPARTAMENTO
DE COMPUTACION

Facultad de Ciencias Exactas y Naturales - UBA




Recorrido de la materia (hasta ahora)



1º parte de la materia

- ✓ Lenguaje de programación (Python)
- ✓ Modelado conceptual de los datos (DER)
- ✓ Representación de los datos (modelo relacional)
- ✓ Formas de consultar los datos (AR/SQL)
- ✓ Recomendaciones para el diseño (Normalización)
- ✓ Calidad de datos
- ✓ Leyes acerca de la Protección de Datos

Recorrido de la materia (hasta ahora)



✓ *Visualización y Exploración de los datos*

Tipos de Aprendizaje Automático

Supervisado

No Supervisado

Aprendizaje por Refuerzo

Tipos de Aprendizaje Automático

Supervisado: Aprende a predecir a partir de datos etiquetados.

No Supervisado

Aprendizaje por Refuerzo

Tipos de Aprendizaje Automático

Supervisado: Aprende a predecir a partir de datos etiquetados.

No Supervisado: Aprende patrones a partir de datos no etiquetados.

Aprendizaje por Refuerzo

Tipos de Aprendizaje Automático

Supervisado: Aprende a predecir a partir de datos etiquetados.

No Supervisado: Aprende patrones a partir de datos no etiquetados.

Aprendizaje por Refuerzo: Toma decisiones a partir de interactuar con el entorno.

Tipos de Aprendizaje Automático

Supervisado : Aprende a predecir a partir de datos etiquetados.

~~No Supervisado: Aprende patrones a partir de datos no etiquetados.~~


~~Aprendizaje por Refuerzo: Toma decisiones a partir de interactuar con el entorno.~~

Tipos de Aprendizaje Automático




Supervisado → Clasificación

~~No Supervisado~~



~~Aprendizaje por Refuerzo~~





Tipos de Aprendizaje Automático





Tipos de Aprendizaje Automático




Tipos de Aprendizaje Automático





Tipos de Aprendizaje Automático



Arranquemos por Regresión Lineal



Regresión lineal simple: Variables discretas - valores continuos



Dimigen, O., Sommer, W., Hohnfeld, A., Jacobs, A. M., & Kliegl, R. (2011). Coregistration of eye movements and EEG in natural reading: analyses and review. *Journal of experimental psychology: General*, 140(4), 552.


Regresión lineal simple: Variables discretas - valores continuos

y = amplitud de la N400

x = Frecuencia de la palabra en el léxico

b = Tamaño del efecto ($\Delta y / \Delta x$ = aumento de la amplitud por cada unidad de frecuencia)

a = Condición base (Toda la actividad asociada a haber visto una palabra que no es la frecuencia)




Regresión lineal simple: Variables discretas - valores continuos

y = amplitud de la N400

x = Frecuencia de la palabra en el léxico

b = Tamaño del efecto ($\Delta y / \Delta x$ = aumento de la amplitud por cada unidad de frecuencia)

a = Condición base (Toda la actividad asociada a haber visto una palabra que no es la frecuencia)




Regresión lineal simple: Variables discretas - valores continuos

$x_i = x$ medido para el punto i

$y_i = y$ medido para el punto i

$f(x_i) = y$ estimado para x_i

$\Delta y_i =$ error en la estimación de y_i



Regresión lineal simple: Variables discretas - valores continuos


$x_i = x$ medido para el punto i

$y_i = y$ medido para el punto i

$f(x_i) = y$ estimado para x_i

$\Delta y_i =$ error en la estimación de y_i

Error = $\sum_{i=1}^N \Delta y_i$



Regresión lineal simple: Variables discretas - valores continuos

$x_i = x$ medido para el punto i

$y_i = y$ medido para el punto i


$f(x_i) = y$ estimado para x_i

$\Delta y_i =$ error en la estimación de y_i

~~Error~~ $= \sum_{i=1}^N \Delta y_i$

Error cuadrático =



$$\sum_{i=1}^N \Delta y_i^2 = \sum_{i=1}^N (f(x_i) - y_i)^2$$



Regresión lineal simple: Variables discretas - valores continuos

$$\text{Error} = \sum_{i=1}^N (f(x_i) - y_i)^2$$



$$\text{Error}(a, b) = \sum_{i=1}^N ((a + b x_i) - y_i)^2$$



Regresión lineal simple: Variables discretas - valores continuos

$$\text{Error} = \sum_{i=1}^N (f(x_i) - y_i)^2$$



$$\text{Error}(a, b) = \sum_{i=1}^N ((a + b x_i) - y_i)^2$$



Regresión lineal simple: Cuadrados mínimos

$$\text{Error} = \sum_{i=1}^N (f(x_i) - y_i)^2$$

$$\text{Error}(a, b) = \sum_{i=1}^N ((a + b x_i) - y_i)^2$$





$$\begin{cases} -2 \sum_{i=1}^n (y_i - a - b x_i) = 0 \\ -2 \sum_{i=1}^n (y_i - a - b x_i) x_i = 0 \end{cases}$$

Regresión lineal simple: Cuadrados mínimos

$$\text{Error} = \sum_{i=1}^N (f(x_i) - y_i)^2$$

$$\text{Error}(a, b) = \sum_{i=1}^N ((a + b x_i) - y_i)^2$$



$$b = \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - \frac{1}{n} \left(\sum_{i=1}^n x_i \right)^2}$$

$$a = \frac{\sum_{i=1}^n x_i^2 \sum_{i=1}^n y_i - \sum_{i=1}^n x_i y_i \sum_{i=1}^n x_i}{n \sum_{i=1}^n x_i^2 - \left(\sum_{i=1}^n x_i \right)^2} = \bar{y} - b \bar{x}$$

Regresión lineal simple: Métricas

$x_i = x$ medido para el punto i

$y_i = y$ medido para el punto i

$f(x_i) = y$ estimado para x_i

$\Delta y_i =$ error en la estimación de y_i

~~Error~~ $\rightarrow \sum_{i=1}^N \Delta y_i$

Error cuadrático =


$$\sum_{i=1}^N \Delta y_i^2 = \sum_{i=1}^N (f(x_i) - y_i)^2$$

Error cuadrático medio (MSE) =

$$(\sum_{i=1}^N (f(x_i) - y_i)^2) / N$$

Error absoluto medio (MAE) =

$$(\sum_{i=1}^N |f(x_i) - y_i|) / N$$



Regresión lineal simple: Métricas


$$\text{Variabilidad total} = \sum_{i=1}^N (y_i - y_{\text{media}})^2 / N$$

$$\text{Variabilidad explicada} = \sum_{i=1}^N (f(x_i) - y_{\text{media}})^2 / N$$

$$R^2 = \text{Variabilidad explicada} / \text{Variabilidad total}$$





Otra interpretación

$R^2 = [\text{Cuánto explica el modelo}] / [\text{Cuánto explica la media}] \Rightarrow \text{Cuánto mejor es el modelo lineal a } \underline{\text{sólo}} \text{ la media}$




Regresión lineal simple: Observaciones atípicas e influyentes

- **Atípicas (outliers en Y):** Observaciones con un patrón distinto al resto de los datos, que producen un residuo grande
- **Influyentes (con alta palanca):** Observaciones cuyo valor de X se encuentra alejado del promedio y que tienen mucho peso en las estimaciones de los parámetros. Al ser eliminadas pueden provocar cambios sustanciales en las estimaciones



Regresión lineal simple: Cuarteto de Anscombe

- Dataset “Anscombe” (1973, Francis Anscombe)
- Muestra la importancia de graficar para visualizar el efecto de datos atípicos y observaciones influyentes sobre las propiedades estadísticas



Regresión lineal múltiple: Varias variables discretas - valores continuos (o discretos)

Regresión lineal múltiple

x_{1i} = valor medido para el punto i y la variable 1

x_{2i} = valor medido para el punto i y la variable 2

y_i = valor medido para el punto i


$f(x_{1i}, x_{2i})$ = y estimado

Δy_i = error en la estimación de y_i

$f(x_1, x_2) = b_0 + b_1x_1 + b_2x_2$

b_1, b_2 = Tamaño del efecto en 1 y 2

$b_0 = a$



Regresión lineal múltiple


$$f(x_1, x_2) = b_0 + b_1 x_1 + b_2 x_2$$

Error cuadrático =

$$\sum_{i=1}^N \Delta y_i^2 = \sum_{i=1}^N (f(x_{1i}, x_{2i}) - y_i)^2$$

$$\sum_{i=1}^N (b_0 + b_1 x_{1i} + b_2 x_{2i} - y_i)^2$$

Ya no puedo hacer la cuenta => Método iterativo




Regresión lineal como predicción

Regresión lineal simple: Predicción

Ahora tengo uno nuevo x^* (por ej. palabra con su predictibilidad)


¿Cuánto su N400?



Regresión lineal simple: Predicción

Ahora tengo uno nuevo x^* (por ej. palabra con su predictibilidad)

¿Cuánto su N400?




Regresión lineal simple: Predicción

Ahora tengo uno nuevo x^* (por ej. palabra con su predictibilidad)

¿Cuánto su N400?

¿Cuán mal estoy prediciendo?




Regresión lineal simple: Predicción

Ahora tengo uno nuevo x^* (por ej. palabra con su predictibilidad)

¿Cuánto su N400?

¿Cuán mal estoy prediciendo?

- Separo en Entrenamiento y Evaluación




Regresión lineal simple: Predicción

Ahora tengo uno nuevo x^ (por ej. palabra con su predictibilidad)*

¿Cuánto su N400?

¿Cuán mal estoy prediciendo?

- *Separo en Entrenamiento y Evaluación*
- *Busco la mejor recta en entrenamiento (igual que antes)*



Notación: Ahora al Error se lo llama Loss Function (Función de pérdida)


Regresión lineal simple: Predicción

Ahora tengo uno nuevo x^* (por ej. palabra con su predictibilidad)

¿Cuánto su N400?

¿Cuán mal estoy prediciendo?

- Separo en Entrenamiento y Evaluación
- Busco la mejor recta en entrenamiento (igual que antes)




Regresión lineal simple: Predicción

Ahora tengo uno nuevo x^* (por ej. palabra con su predictibilidad)

¿Cuánto su N400?

¿Cuán mal estoy prediciendo?

- Separo en Entrenamiento y Evaluación
- Busco la mejor recta en entrenamiento (igual que antes)
- Calculo el error (MSE, MAE, R^2 , Corr)



Regresión lineal simple: Predicción


Ahora tengo uno nuevo x^ (por ej. palabra con su predictibilidad)*

¿Cuánto su N400?

¿Cuán mal estoy prediciendo?

- *Separo en Entrenamiento y Evaluación*
- *Busco la mejor recta en entrenamiento (igual que antes)*
- *Calculo el error (MSE, MAE, R^2 , Corr)*

Y eventualmente puedo volver a los puntos que no vi nunca...



Regresión lineal simple: Predicción


Ahora tengo uno nuevo x^ (por ej. palabra con su predictibilidad)*

¿Cuánto su N400?

¿Cuán mal estoy prediciendo?


- *Separo en Entrenamiento y Evaluación*
- *Busco la mejor recta en entrenamiento (igual que antes)*
- *Calculo el error (MSE, MAE, R^2 , Corr)*

Y eventualmente puedo volver a los puntos que no vi nunca...




Errores y Sesgos


Bajo error




Alto error



Errores y Sesgos





~~Errores~~ Varianza y Sesgos




~~Errores~~ Varianza y Sesgos

TRAINING-SET PERFORMANCE vs. TEST-SET PERFORMANCE




James, G. G. M., Witten, D., Hastie, T. J., Tibshirani, R. J., & Taylor, J. E. (2023). An introduction to statistical learning: with applications in Python. Springer

~~Errores~~ Varianza y Sesgos




James, G. G. M., Witten, D., Hastie, T. J., Tibshirani, R. J., & Taylor, J. E. (2023). An introduction to statistical learning: with applications in Python. Springer

~~Errores~~ Varianza y Sesgos



James, G. G. M., Witten, D., Hastie, T. J., Tibshirani, R. J., & Taylor, J. E. (2023). An introduction to statistical learning: with applications in Python. Springer

Sobreajuste



James, G. G. M., Witten, D., Hastie, T. J., Tibshirani, R. J., & Taylor, J. E. (2023). An introduction to statistical learning: with applications in Python. Springer

Regresión lineal regularizada

Regresión lineal regularizada


Ahora tengo uno nuevo x^* (por ej. palabra con su predictibilidad)

¿Cuánto su N400?

¿Cuán mal estoy prediciendo?

- Separo en Entrenamiento y Evaluación
- Busco la mejor recta en entrenamiento ~~(igual que antes)~~

Antes: $\sum_{i=1}^N (f(x_{1i}, x_{2i}) - y_i)^2$



Regresión lineal regularizada

Ahora tengo uno nuevo x^* (por ej. palabra con su predictibilidad)


¿Cuánto su N400?

¿Cuán mal estoy prediciendo?

- Separo en Entrenamiento y Evaluación
- Busco la mejor recta en entrenamiento ~~(igual que antes)~~

Antes: $\sum_{i=1}^N (f(x_{1i}, x_{2i}) - y_i)^2$

Ahora: $\sum_{i=1}^N (f(x_{1i}, x_{2i}) - y_i)^2 + \sum_{j=0}^2 b_j^2$



Regresión lineal regularizada

Ahora tengo uno nuevo x^* (por ej. palabra con su predictibilidad)

¿Cuánto su N400?


¿Cuán mal estoy prediciendo?

- Separo en Entrenamiento y Evaluación
- Busco la mejor recta en entrenamiento ~~(igual que antes)~~

Antes: $\sum_{i=1}^N (f(x_{1i}, x_{2i}) - y_i)^2$

Ahora: $\sum_{i=1}^N (f(x_{1i}, x_{2i}) - y_i)^2 + \sum_{j=0}^2 b_j^2$

¿Cuándo sirve?



Regresión lineal regularizada

Ahora tengo uno nuevo x^* (por ej. palabra con su predictibilidad)

¿Cuánto su N_{400} ?


¿Cuán mal estoy prediciendo?

- Separo en Entrenamiento y Evaluación
- Busco la mejor recta en entrenamiento ~~(igual que antes)~~

Antes: $\sum_{i=1}^N (f(x_{1i}, x_{2i}) - y_i)^2$

Ahora: $\sum_{i=1}^N (f(x_{1i}, x_{2i}) - y_i)^2 + \sum_{j=0}^2 b_j^2$


¿Cuándo sirve? Muchas variables, sobre todo muchas variables correlacionadas



Regresión lineal regularizada


$$RIDGE: \sum_{i=1}^N (f(x_{1i}, x_{2i}) - y_i)^2 + \sum_{j=0}^2 b_j^2$$

$$LASSO: \sum_{i=1}^N (f(x_{1i}, x_{2i}) - y_i)^2 + \sum_{j=0}^2 |b_j|$$



Clasificación


Generalización (Entrenamiento-Evaluación)




○ Atentos

✕ Dormidos



Generalización (Entrenamiento-Evaluación)




Generalización (Entrenamiento-Evaluación)





- Atentos
- ✕ Dormidos




Generalización (Entrenamiento-Evaluación)




- Atentos
- ✕ Dormidos




Generalización (Entrenamiento-Evaluación)



- Atentos
- ✕ Dormidos




Conjunto de
entrenamiento




Conjunto de
evaluación



Evaluación





Evaluación: Toma de decisiones



Evaluación: Toma de decisiones



Evaluación: Toma de decisiones





Evaluación: Métricas




perro




muffin




Evaluación: Matriz de Confusión




		Valor decidido	
		Positivo	Negativo
Valor real	Positivo	True Positive (TP)	False Negative (FN)
	Negativo	False Positive (FP)	True Negative (TN)




Evaluación: Matriz de Confusión




		Valor decidido	
		Positivo (PERRO)	Negativo (MUFFIN)
Valor real	Positivo 	 PERRO	
	Negativo 		




Evaluación: Matriz de Confusión




		Valor decidido	
		Positivo (PERRO)	Negativo (MUFFIN)
Valor real	Positivo 	 PERRO	
	Negativo 		 MUFFIN




Evaluación: Matriz de Confusión




		Valor decidido	
		Positivo (PERRO)	Negativo (MUFFIN)
Valor real	Positivo 	 PERRO	 MUFFIN
	Negativo 		 MUFFIN



Evaluación: Matriz de Confusión



		Valor decidido	
		Positivo (PERRO)	Negativo (MUFFIN)
Valor real	Positivo	 PERRO	 MUFFIN
	Negativo	 PERRO	 MUFFIN



Evaluación: Matriz de Confusión

		Valor decidido	
		Positivo (PERRO)	Negativo (MUFFIN)
Valor real	Positivo 	 PERRO	 MUFFIN
	Negativo 	 PERRO	 MUFFIN

Evaluación: Matriz de Confusión

		Valor decidido	
		Positivo (PERRO)	Negativo (MUFFIN)
Valor real	Positivo 	 PERRO	 MUFFIN Error Tipo II
	Negativo 	 PERRO Error Tipo I	 MUFFIN

Evaluación: Matriz de Confusión

		Valor decidido	
		Positivo (PERRO)	Negativo (MUFFIN)
Valor real	Positivo 	 PERRO	 MUFFIN Error Tipo II
	Negativo 	 PERRO Error Tipo I	 MUFFIN

Evaluación: Matriz de Confusión

Valor
real


Valor decidido

	Valor decidido	
	Positivo	Negativo
Positivo	True Positive (TP)	False Negative (FN)
Negativo	False Positive (FP)	True Negative (TN)


Error Tipo II

Error Tipo I

Type I error
(false positive)



Type II error
(false negative)



Evaluación: Accuracy

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}$$

Definición

Mide la proporción de predicciones correctas hechas por el modelo sobre el total de predicciones.

Pros

Es sencilla de entender.

Contras

No refleja el desequilibrio de clases.

No considera la gravedad de los errores.

		Valor decidido	
		Pos.	Neg.
Valor real	Pos.	True Positive (TP)	False Negative (FN)
	Neg.	False Positive (FP)	True Negative (TN)

Ejemplo: Accuracy

1% de las mujeres tienen cáncer de mama. Desarrollaron un test que tiene esta performance.

	Cancer (1%)	No Cancer (99%)
Test Pos	80%	9.6%
Test Neg	20%	90.4%

Es decir:

- 1% de los casos es positivo
 - De los casos positivos, el 80% testea positivo.
 - De los negativos, 9.6% testea positivo.
- ¿Cómo es la matriz de confusión?

$$\begin{pmatrix} 0.01 \cdot 0.8 & 0.99 \cdot 0.096 \\ 0.01 \cdot 0.2 & 0.99 \cdot 0.904 \end{pmatrix}$$

¿SUMA 100%?

Ejemplo: Accuracy

- ¿Cuánto es el accuracy?
- ¿Si el test da positivo, significa que el paciente tiene la enfermedad?

$$\begin{pmatrix} 0.01*0.8 & 0.99*0.096 \\ 0.01*0.2 & 0.99*0.904 \end{pmatrix}$$

Evaluación: Precision y Recall

Precision

Proporción de los positivos que son correctamente identificados por el modelo sobre el total de las muestras positivas

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

Recall / Sensitivity

Proporción de verdaderos positivos que fueron correctamente identificados por el modelo sobre el total de casos reales positivos.

		Valor decidido	
		Pos.	Neg.
Valor real	Pos.	True Positive (TP)	False Negative (FN)
	Neg.	False Positive (FP)	True Negative (TN)

Evaluación: Precision y Recall

Precision

Proporción de los positivos que son correctamente identificados por el modelo sobre el total de las muestras positivas

$$\text{Precision} = \frac{TP}{TP + FP}$$

Recall / Sensitivity

Proporción de verdaderos positivos que fueron correctamente identificados por el modelo sobre el total de casos reales positivos.

$$\text{Recall} = \frac{TP}{TP + FN}$$

		Valor decidido	
		Pos.	Neg.
Valor real	Pos.	True Positive (TP)	False Negative (FN)
	Neg.	False Positive (FP)	True Negative (TN)

Evaluación: F-Score

$$\text{F-score} = (1 + \beta^2) \frac{\text{Precision} * \text{Recall}}{\beta^2 \text{Precision} + \text{Recall}}$$

Pros

Contempla tanto *Precision* como *Recall*.

Adaptabilidad (al modificar β).

Contras


Más compleja de entender.

No es claro qué impacto tiene β .

No proporciona detalles específicos del impacto de cada error. Siempre va a preferir más selección de la clase positiva.

Evaluación: Curva ROC (Receiver-Operator Curve)

Representación gráfica de la **sensibilidad** frente a la **especificidad** para un sistema clasificador binario según se varía el umbral de discriminación.



Aumenta el número de verdaderos positivos, el modelo es más sensible pero menos específico...
Aumenta el número de falsos positivos.

Sensibilidad

$$\frac{TP}{(TP + FN)}$$

Especificidad


$$\frac{TN}{(TN + FP)}$$

↓

$$\frac{FP}{TN + FP}$$

Evaluación: Curva ROC (Receiver-Operator Curve)

Representación gráfica de la **sensibilidad** frente a la **especificidad** para un sistema clasificador binario según se varía el umbral de discriminación.



Sensibilidad

$$\frac{TP}{(TP + FN)}$$


Especificidad

$$\frac{TN}{(TN + FP)}$$

$$\frac{FP}{TN + FP}$$

Evaluación: Curva ROC (Receiver-Operator Curve)

Representación gráfica de la **sensibilidad** frente a la **especificidad** para un sistema clasificador binario según se varía el umbral de discriminación.



Área bajo la curva (AUC), cuanto más cerca de cubrir el cuadrado, es decir de llegar a 1, ¡Mejor!

Sensibilidad

$$\frac{TP}{(TP + FN)}$$

Especificidad

$$\frac{TN}{(TN + FP)}$$

↓

$$\frac{FP}{TN + FP}$$

Evaluación: Clasificación Categórica

		Valor decidido		
		Perro	Piedra	Muffin
Valor real	Perro			
	Piedra			
	Muffin			

Evaluación: Clasificación Categórica

		Valor decidido	
		Perro	No perro
Valor real	Perro		
	No perro		 


Evaluación: Clasificación Categórica

Clasificación
Accuracy
Precision - Recall
F1
AUC - ROC
...

		Valor decidido	
		Perro	No perro
Valor real	Perro		
	No perro		 

Esquemas de entrenamiento

División de datos




División de datos

Entrenamiento


Testeo

Evaluación

División de datos: Cross-Validation (Validación Cruzada)



División de datos: Bootstrapping



Bibliografía



Libros:

- Introduction to Machine Learning with Python, Müller & Guido
- Machine Learning - Mitchell

- James, G. G. M., Witten, D., Hastie, T. J., Tibshirani, R. J., & Taylor, J. E. (2023). An introduction to statistical learning: with applications in Python. Springer
- Stegmayer, G., Milone, D., Ferrer, L., Fernandez Slezak, D., Alonso Alemany, L., & Ferrante, E. (2022). ¿Aprendizaje automático?: Un viaje al corazón de la inteligencia artificial contemporánea.

https://bibliotecavirtual.unl.edu.ar:8443/bitstream/handle/11185/6682/VERA_kuaa_Ferrante_AA.pdf?sequence=1&isAllowed=y

- Ferrer, L. Analysis and Comparison of Classification Metrics
<https://arxiv.org/abs/2209.05355>



Ejemplos: Decision Trees


Ejemplo

Tenemos un conjunto de datos con variables $x1$, $x2$, y .

- Variables explicativas continuas $x1$, $x2$
- Variable a explicar y categórica

Graficamos $x1$, $x2$ en los ejes.

La variable a explicar toma 3 valores: Clase 1, Clase 2, Clase 3 y se representa con símbolos/colores.



A scatter plot showing the distribution of three classes (Clase 1, Clase 2, and Clase 3) based on two attributes: Atributo x1 (horizontal axis) and Atributo x2 (vertical axis). The plot includes a legend in the top-left corner identifying the classes by color and shape: Clase 1 (purple square), Clase 2 (teal circle), and Clase 3 (yellow triangle). A red 'X' marks a specific data point within the Clase 3 cluster at approximately (6.2, 3.2).


¿Qué clase le asignamos a la nueva observación?

Métodos posibles (hay más)


- Umbral ($x_1 > c$)
- K-Nearest Neighbors (KNN) [Clase pasada]
- Regresión logística
- Árboles de decisión
- Support Vector Machines (SVM)
- Random Forest
- Boosting
- Redes Neuronales
- etc...

Dataset de flores - Iris


Iris setosa



Iris versicolor



Iris virginica



50 muestras de cada una de tres especies de flores *Iris*: *setosa*, *versicolor* y *virginica*. De cada flor se midieron 4 atributos: largo y ancho del sépalo y del pétalo.

Fisher - 1936

Clasificación de Flores





¿Ante las medidas de una nueva flor, cómo podríamos determinar su especie?

¿Cuál resulta el atributo más importante a la hora de distinguir entre especies?

¿Qué herramienta puede ayudarnos a responder esto?

Histogramas




Histogramas de los 4 atributos




{0: 'setosa', 1: 'versicolor', 2: 'virginica'}

Histogramas

Histogramas de los 4 atributos



¿Cuál atributo separa mejor las clases?



Clasificamos por largo del pétalo

```
def clasificador_iris
```



Clasificamos por largo del pétalo

Ahora veamos cómo se comporta este clasificador.




¿Podemos mejorar el clasificador?

¿Cómo comparamos entre dos clasificadores?

Clasificamos por largo del pétalo


Ahora veamos cómo se comporta este clasificador.

Éstas son las líneas de corte.




Árboles de decisión

- método para **inferencia inductiva**
- aprenden **reglas if-then** sobre los valores de los atributos. Predicen valor objetivo en función de las reglas.



Árboles de decisión - Ejemplo



Árboles de decisión - Ejemplo



nodo: representa pregunta

aristas: representan posibles respuestas

hojas: nodos que representan decisiones

caminos desde la raíz

Árboles de decisión

- Modelo de aprendizaje supervisado utilizado principalmente para **clasificación**.
- Se basa en el armado de una **jerarquía de reglas**. Estas las podemos expresar usando una fórmula lógica de ANDs y ORs.
- Es decir que el árbol representa una **disyunción de conjunciones sobre valores de atributos**.

Podemos pensar el armado del árbol como jugar al ¿Quién es quién?.

Los árboles son un *modelo altamente interpretable*. Es decir que dada una predicción particular podemos entender por qué el modelo la generó. Sólo hay que mirar la rama de la hoja correspondiente a la predicción.




Dataset Titanic

El Titanic se hundió en Abril de 1912.

Tenía la fama de ser “Inhundible” pero chocó con un iceberg y no le alcanzó con la fama.

Como no había suficientes salvavidas 1502 de 2224 pasajeros y personal de a bordo murieron.



Dataset en:

<https://www.kaggle.com/competitions/titanic>

PassengerId	Pclass	Sex	Age	SibSp	Parch	Fare
1	2	1 female	38.0	1	0	71.2833
3	4	1 female	35.0	1	0	53.1000
6	7	1 male	54.0	0	0	51.8625
10	11	3 female	4.0	1	1	16.7000
11	12	1 female	58.0	0	0	26.5500

Objetivo: ¿Podemos predecir quienes sobrevivieron al titanic?

Actividad Titanic

Consigna 1: ¿Qué características tenían los pasajeros que sobrevivieron? ¡Explore los datos y escribanlas en un papel (o grafíquenlas)!

Algunas preguntas:

- ¿Cuántos pasajeros de primera clase había? ¿Y de segunda y tercera?
- ¿Cuál era la proporción de niños?
- ¿Quiénes les parece que tenían prioridad en los botes de rescate?

Actividad Titanic

Consigna 2: Tenemos los datos de una pasajera, ¿pueden decir si sobrevivió o no?

	Pclass	Sex	Age	SibSp	Parch	Fare	Survived
184	1	female	27.0	1	1	247.5208	???

¿Adivinaron o usaron reglas? ¿Cuáles? ¿Se pueden generalizar?

Actividad Titanic

Consigna 3: Competencia

PassengerId	Pclass	Sex	Age	SibSp	Parch	Fare
-------------	--------	-----	-----	-------	-------	------

Ahora les voy a dar los datos de **10 pasajeros**,

¿Pueden responder cuáles sobrevivieron?


Armar un conjunto de reglas generales, basadas solamente en los atributos indicados.
Generar etiquetas para estos 10 pasajeros.


```
def clasificador_titanic(x):  
    vive = False  
    if REGLA:  
        vive = True  
    return vive
```

Subir sus predicciones y el código que usaron para sus reglas a un google form.

Tienen 10 min!

<https://www.online-stopwatch.com/timer/15minute/>






```
def clasificador_titanic(x):  
    vive = False  
    if x.Sex == "female":  
        vive = True  
    elif x.Age < 5 or x.Pclass == 1 :  
        vive = True  
    return vive
```

SCORE : 50%
(5 instancias bien clasificadas)

*Cada nodo interno evalúa un atributo discreto **a***
*Cada rama corresponde a un **valor/umbral** para **a***
*Cada hoja predice un valor de **Y***

Esto que hicimos a ojo se puede formalizar como un método de Aprendizaje Supervisado

Árboles de decisión



El árbol representa una **disyunción de conjunciones sobre valores de atributos**.

En el ejemplo la fórmula quedaría:

$$(Sex == Female) \vee (Age < 5) \vee (Age \geq 5 \wedge Pclass == 1)$$

Inducción Top-Down para árboles de decisión

(versión simplificada de ID-3 y C4.5 (Quinlan))

Input: S un conjunto de instancias con atributos A .

1. Elegimos $a \in A$, el atributo que produce el **mejor corte** de S para el nodo actual.
2. Para cada valor v_i posible de a , crear un nuevo hijo del nodo actual.
3. Clasificar (repartir) las instancias en los nuevos nodos, según el valor del atributo a .

$$S_i \leftarrow \{ x \mid x \in S \wedge x[a] = v_i \}$$


4. Repetir para cada hijo del nodo en el que haya instancias de más de una clase (salvo que se cumpla algún criterio de corte en cuyo caso terminamos).

¿Cómo definimos el mejor corte?
→ Necesitamos métricas!!




Árboles de decisión - Medidas de impureza

 → SOBREVIVIO
 → NO SOBREVIVIO



¿Cuál corte es mejor? ¿Qué lo hace mejor? ¿Cómo medirían esto?

Árboles de decisión - Medidas de impureza



Bajó mucho la
impureza
Buena elección de
pregunta

No bajó mucho la
impureza

Árboles de decisión - Medidas de impureza



$$\Delta M = M(S) - \left(\frac{|S_{\text{sí}}|}{|S|} M(S_{\text{sí}}) + \frac{|S_{\text{no}}|}{|S|} M(S_{\text{no}}) \right)$$




¿cuánto gano, según la medida M , si divido a S en regiones con una pregunta?

Árboles de decisión - Medidas de impureza

Entropía

Mide la incertidumbre inherente a los posibles resultados de una variable aleatoria.


Voy a sacar una bolita. ¿Cuánta incertidumbre hay?




Árboles de decisión - Medidas de impureza

$$H = - \sum p_i \log_2(p_i)$$


$$p_A = 7/8, P_R = 1/8$$
$$H = 0.544$$



$$p_A = 6/8, P_R = 2/8$$
$$H = 0.811$$



$$p_A = 4/8, P_R = 4/8$$
$$H = 1$$



Árboles de decisión - Medidas de impureza

Info Gain (Ganancia de Información)

Mide cuánta entropía removemos al hacer un corte.

A menor entropía, mayor información.

$$\text{InfoGain} = H(S) - \left(\frac{|S_{\text{sí}}|}{|S|} H(S_{\text{sí}}) + \frac{|S_{\text{no}}|}{|S|} H(S_{\text{no}}) \right)$$

$$H(S) = - \sum_{k \in S} p_S(k) \log_2 p_S(k)$$

Árboles de decisión - Medidas de impureza


Impureza de Gini

Mide la probabilidad de que una instancia particular sea clasificada erróneamente si esta fuese etiquetada aleatoriamente de acuerdo con la distribución de clases dentro de la región.


$$G(S) = 1 - \sum_{k \in S} p_S(k)^2$$

$$G = 1 - \sum p_i^2$$


$$p_A = 7/8, P_R = 1/8$$
$$G = 0,21875$$



$$p_A = 6/8, P_R = 2/8$$
$$G = 0,375$$



$$p_A = 4/8, P_R = 4/8$$
$$G = 0.5$$



Árboles de decisión - Medidas de impureza


Gini Gain

Mide la probabilidad de que una instancia particular sea clasificada erróneamente si esta fuese etiquetada aleatoriamente de acuerdo con la distribución de clases dentro de la región.

$$\text{GiniGain} = G(S) - \left(\frac{|S_{\text{sí}}|}{|S|} G(S_{\text{sí}}) + \frac{|S_{\text{no}}|}{|S|} G(S_{\text{no}}) \right)$$


$$G(S) = 1 - \sum_{k \in S} p_S(k)^2$$


Gini Index and Entropy vs. Class Probability



Fronteras de decisión



El tipo de regiones de decisión que puede generar un árbol de decisión tienen forma de rectángulos.







Ejemplo del libro de Müller & Guido



depth = 1





depth = 2



depth = 2



depth = 9



Sesgo inductivo

Se denomina sesgo inductivo de un algoritmo de aprendizaje automático al conjunto de afirmaciones que el algoritmo utiliza para construir un modelo.

- Incluye:
 - forma de las hipótesis
 - características de funcionamiento del algoritmo (cómo recorre el espacio de hipótesis hasta elegir un único modelo)



Sesgo inductivo

- El tipo de regiones de decisión que puede generar tienen forma de rectángulos, con cortes paralelos a los ejes.
- Las regiones que exploramos se determinan de manera *Greedy*. En cada paso optamos por mejorar la métrica de manera local. No se revisan decisiones previas. No se consideran todas las combinaciones de regiones posibles.

Overfitting - Sobreajuste

En árboles de decisión, hay sobreajuste cuando el árbol es “demasiado” profundo

¿Qué pasa si hay **descripciones exactas de instancias únicas y aisladas**?



Fernando Berzal, DECSAI, Universidad de Granada

Overfitting en Árboles de Decisión - Cómo evitarlo

Soluciones:

- **detener crecimiento del árbol** antes de que clasifique perfectamente a los datos
- **hacer crecer el árbol entero, luego podar (post-prune)**

Resumen

- aprendizaje supervisado
- para clasificación y regresión
- fáciles de usar y de entender
- buen método exploratorio para ver qué atributos son importantes
- sesgo, overfitting

Ventajas:

- son altamente interpretables
- fácil visualización
- se pueden usar atributos binarios, categóricos o continuos

Desventajas:

- pueden tener sobreajuste
- suelen necesitarse ensambles de árboles para tener mejor performance

En Python



```
class sklearn.tree.DecisionTreeClassifier(*, criterion='gini', splitter='best', max_depth=None, min_samples_split=2, min_samples_leaf=1, min_weight_fraction_leaf=0.0, max_features=None, random_state=None, max_leaf_nodes=None, min_impurity_decrease=0.0, class_weight=None, ccp_alpha=0.0)
```

[\[source\]](#)

```
from sklearn.tree import DecisionTreeClassifier
```

```
arbol = DecisionTreeClassifier()
```

```
arbol.fit(X, y) # Entrenamiento del modelo
```


```
prediction = arbol.predict(X) # Generamos las predicciones // llamamos al modelo
```

Hiperparámetros

→ Son los parámetros que nos permiten configurar el modelo.

Por ejemplo, la altura máx del árbol de decisión.

Ejemplo con Iris



Representación del árbol

```
### representarlo gráficamente
```

```
plt.figure(figsize= [20,10])  
tree.plot_tree(clf_info, feature_names = ['altura_tot', 'diametro',  
'inclinacio'], class_names = ['Ceibo', 'Eucalipto', 'Jacarandá',  
'Pindó'],filled = True, rounded = True, fontsize = 8)
```

```
### otra forma de ver el arbol
```

```
r = tree.export_text(clf_info, feature_names=['altura_tot', 'diametro',  
'inclinacio'])  
print(r)
```

```
###
```

Ejercicios

- Ajustar un árbol de decisión para el problema de Titanic.
- Probar con distintas profundidades, y con criterios Entropy y Gini.
- Comparar con el clasificador que hicieron a mano para la competencia.
 - ¿Se usan los mismos atributos?

Tarea

Resolver la guía de ejercicios de clasificación con árboles de decisión.



Bibliografía

Libros:

- Introduction to Machine Learning with Python, Müller & Guido
- Machine Learning - Mitchell

Artículos:

- Induction of Decision Trees. Quinlan.
<http://hunch.net/~coms-4771/quinlan.pdf>
- Simplifying Decision Trees. Quinlan.
<https://www.sciencedirect.com/science/article/pii/S0020737387800536>



Ejemplos: K Nearest Neighbors (KNN)


Ejemplo

Tenemos un conjunto de datos con variables x_1 , x_2 , y .

- Variables explicativas continuas x_1 , x_2
- Variable a explicar y categórica

Graficamos x_1 , x_2 en los ejes.

La variable a explicar toma 3 valores: Clase 1, Clase 2, Clase 3 y se representa con símbolos/colores.



¿Qué clase le asignamos a la nueva observación?

Ejemplo

Tenemos un conjunto de datos con variables x_1 , x_2 , y .


- Variables explicativas continuas x_1 , x_2
- Variable a explicar y categórica

Graficamos x_1 , x_2 en los ejes.


La variable a explicar toma 3 valores: Clase 1, Clase 2, Clase 3 y se representa con símbolos/colores.

¿Qué clase le asignamos a la nueva observación?


Iris setosa



Iris versicolor




Iris virginica



50 muestras de cada una de tres especies de flores *Iris*: *setosa*, *versicolor* y *virginica*. De cada flor se midieron 4 atributos: largo y ancho del sépalo y del pétalo.

Fisher - 1936


Scatterplot por clases



Clasificación

A ojo: ¿Qué clase será?

Una idea puede ser: mirar
alrededor.



K Nearest Neighbors (KNN)

Para determinar la clase de una nueva observación:

1. Buscar los puntos más cercanos, dentro del conjunto de entrenamiento
2. Ver qué clases tienen
3. Elegir la mayoritaria


¿Cuántos puntos consideramos? Depende del valor de k .

K Nearest Neighbors (KNN)

Si $k = 1$:

Buscamos el vecino más cercano, entre ya tenemos etiquetados.

Nos copiamos esa etiqueta.




K Nearest Neighbors (KNN)

Si $k = 3$:

Buscamos los 3 más cercanos, entre los que ya tenemos etiquetados.

Tomamos la clase mayoritaria.




K Nearest Neighbors (KNN)

Si $k = 5$.

Buscamos los 5 más cercanos, entre los que ya tenemos etiquetados.


Tomamos la clase mayoritaria.



Clasificación con K Nearest Neighbors (KNN)

- Depende de k
- Depende de los atributos elegidos
- Depende de la distancia elegida para determinar cercanía


Clasificación con *K* Nearest Neighbors (KNN)




Conjunto de datos *etiquetados*.
Dada una *nueva* observación, la
misma será clasificada según la
proporción de clases en su
entorno.

Clasificación con K Nearest Neighbors (KNN)

$$K = 1$$




Dada una nueva observación, la misma será clasificada según si cae en la zona **verde** o en la zona **lila**.




$K = 2$

*Clasificación con K Nearest
Neighbors (KNN)*




$K = 3$

*Clasificación con K Nearest
Neighbors (KNN)*




$K = 4$

*Clasificación con K Nearest
Neighbors (KNN)*




$K = 5$

*Clasificación con K Nearest
Neighbors (KNN)*




$K = 6$

*Clasificación con K Nearest
Neighbors (KNN)*



$K = 13$

*Clasificación con K Nearest
Neighbors (KNN)*



$K = 20$

*Clasificación con K Nearest
Neighbors (KNN)*

Clasificación con K Nearest Neighbors (KNN)

¿Cómo cambia el clasificador a medida que aumenta el valor de k ?

Clasificación con K Nearest Neighbors (KNN) con sklearn

```
# importar paquete de sklearn
from sklearn.neighbors import KNeighborsClassifier

# construir el modelo
clasificador = KNeighborsClassifier(n_neighbors = K)

# entrenar el modelo con datos
# X son los atributos, y son las etiquetas
clasificador.fit(X, y)

# utilizar el modelo para predecir nuevo(s) casos(s)
prediccion = clasificador.predict(Xnuevo)
```

Ejemplo - clasificación binaria

Entrenaremos un clasificador binario para predecir si un paciente tiene o no diabetes.

Objetivo del modelo: Predecir si un paciente tiene o no diabetes basándose en determinadas mediciones incluidas en el conjunto de datos.

Se trata de un recorte de una base de datos más amplia. En particular, todos los pacientes son mujeres de al menos 21 años y de ascendencia india pima.

Consigna

- Trabajar con los datos de diabetes.
- Construir un clasificador basado en ['Glucose', 'BMI'], probar con distintos valores de k , determinar el diagnóstico para una paciente con valores de glucosa = 130 y BMI = 32.
- Construir un clasificador basado en otro conjunto de atributos y comparar resultados.
- Evaluar los resultados

Ejemplo - datos sintéticos

Trabajamos con datos sintéticos para ver cómo cambia la frontera de decisión.

Consigna

- Utilizando `from sklearn.datasets import make_moons` construir un dataset “moons” con 200 datos y ruido = 0.2.
- Construir y entrenar un clasificador con $k = 5$ y graficar la frontera de decisión.
- Comparar con otros valores posibles para k .
- Evaluar los resultados

Bibliografía

Libros:

- Introduction to Machine Learning with Python, Müller & Guido
- Machine Learning - Mitchell

