


Visualización y Análisis Exploratorio de Datos

Parte 1

Laboratorio de Datos · 2026

Manuela Cerdeiro - Paula Perez Bianchi - Viviana Cotik


Recorrido



1º parte de la materia

- Lenguaje de programación (Python)
- Modelado conceptual de los datos (DER)
- Representación de los datos (modelo relacional)
- Formas de consultar los datos (AR/SQL)
- Recomendaciones para el diseño (Normalización)
- Calidad de datos

Clase de hoy



2º parte de la materia



- Visualización y Exploración de los datos

Para qué visualizar

Para qué visualizar

Al transformar los números y otras piezas de información en gráficos, el contenido se hace más fácil de **entender y usar**.

- Resumir información
- Encontrar tendencias o patrones
- Detectar valores anómalos
- Encontrar relaciones entre variables
- Hacerse preguntas y elaborar hipótesis
- Mostrar o reforzar una hipótesis
- Mostrar resultados


Ejemplo: encontrar tendencias o patrones

TABLE 1.1


Zoo Attendance Data

Month	Jan	Feb	Mar	Apr	May	Jun
Attendance	5422	4878	6586	6943	7876	17843
Month	July	Aug	Sept	Oct	Nov	Dec
Attendance	21967	14542	8751	6454	5677	11422

¿Cómo varía la asistencia al zoológico a lo largo del tiempo?

FIGURE 1.1**A Column Chart of Zoo Attendance by Month**

- La asistencia aumenta en junio y julio, cuando los niños en edad escolar no asisten a la escuela (vacaciones de verano — hemisferio norte).
- Aumento gradual de la asistencia con la temperatura (desde febrero hasta mayo).

FIGURE 1.1**A Column Chart of Zoo Attendance by Month**

La asistencia en diciembre no sigue estos patrones → El zoo cuenta con el "Festival de las Luces" que se extiende desde finales de noviembre hasta principios de enero. También corresponde al periodo de vacaciones de invierno de los niños en edad escolar.


Visualización de datos según la finalidad

La **exploración** visual de datos es una parte crucial del análisis descriptivo.

La exploración de datos permite:

- Identificar patrones
- Reconocer anomalías e irregularidades
- Caracterizar la relación entre variables

La visualización nos da mayor capacidad para detectar patrones, anomalías y relaciones entre variables que al hacerlo mirando simplemente los datos crudos.



Mostrar o reforzar una hipótesis


Queremos mostrar que la "Cultura de la compañía" es uno de los factores más importantes a la hora de buscar trabajo.

¿Resulta
obvio?

Factor	Porcentaje
Flexible Schedule	11,00%
Location	13,00%
Salary and Bonus	24,00%
Job Title	6,00%
Health Benefit Benefits	5,00%
Industry	8,00%
Company Culture	22,00%
Day-to-day Work	11,00%

Queremos mostrar que la "Cultura de la compañía" es uno de los factores más importantes a la hora de buscar trabajo.

¿Resulta obvio?



La visualización de datos es útil para comunicar a la audiencia y garantizar que comprenda y se concentre en el mensaje deseado.

Tipos de datos

El tipo de gráfico a realizar depende de las características de los datos con los que se cuenta:

Tipo de variable

- Nominales — categorías
- Ordinales — escalas discretas, rankings
- Cuantitativos — magnitudes
- Proporciones — comparaciones de magnitudes

Estructura - temporal

- Transversales
- Series temporales

Tipos de datos: cuantitativos vs categóricos

¿Qué tipo de variable es Length?

Variable cuantitativa

Sex	Length	Diameter	Height	Weight	Shucked Weight	Viscera Weight	Shell Weight	Age
F	16875	1275	375	3392017675	134660125	8618248	10942907	11
M	11	8875	3125	1353688625	3742134	231048425	5386405	9
F	15	1175	475	3216250775	13947954	735669525	956795625	10
M	13125	9625	25	1450076925	6973977	284912475	412485225	8
I	9875	675	25	846232575	409650275	17293195	2324659	5
I	13125	1	35	1971707725	681805475	453592	71724235	10
F	1325	1075	375	210069795	92135875	525883225	5556502	9
I	11375	9375	3125	151102835	66054335	3005047	52446575	8
I	1075	85	275	1033339275	45075705	242388225	29766975	7
M	1325	11	5125	236718325	907184	616601625	69456275	14
M	15375	13125	3875	3224755625	104042665	6690482	10489315	20
F	13125	10125	4	18653971	752679225	318931875	63786375	12

Variables cuantitativas:

- Permiten indicar una magnitud.
- Se les puede aplicar operaciones aritméticas (+, -, *, %, etc.).

Tipos de datos: cuantitativos vs categóricos

¿Qué tipo de variable es Sex?

Variable categórica

Sex	Length	Diameter	Height	Weight	Shucked Weight	Viscera Weight	Shell Weight	Age
F	16875	1275	375	3392017675	134660125	8618248	10942907	11
M	11	8875	3125	1353688625	3742134	231048425	5386405	9
F	15	1175	475	3216250775	13947954	735669525	956795625	10
M	13125	9625	25	1450076925	6973977	284912475	412485225	8
I	9875	675	25	846232575	409650275	17293195	2324659	5
I	13125	1	35	1971707725	681805475	453592	71724235	10
F	1325	1075	375	210069795	92135875	525883225	5556502	9
I	11375	9375	3125	151102835	66054335	3005047	52446575	8
I	1075	85	275	1033339275	45075705	242388225	29766975	7
M	1325	11	5125	236718325	907184	616601625	69456275	14
M	15375	13125	3875	3224755625	104042665	6690482	10489315	20
F	13125	10125	4	18653971	752679225	318931875	63786375	12

Variables categóricas:

- Permiten identificar ítems similares mediante etiquetas o nombres.
- No se pueden realizar operaciones aritméticas. Sin embargo, se pueden sintetizar contando observaciones o calculando proporciones.

Tipos de datos: transversales vs series temporales

Los datos de esta tabla ¿Son transversales o corresponden a una serie temporal?

Sex	Length	Diameter	Height	Weight	Shucked Weight	Viscera Weight	Shell Weight	Age
F	16875	1275	375	3392017675	134660125	8618248	10942907	11
M	11	8875	3125	1353688625	3742134	231048425	5386405	9
F	15	1175	475	3216250775	13947954	735669525	956795625	10
M	13125	9625	25	1450076925	6973977	284912475	412485225	8
I	9875	675	25	846232575	409650275	17293195	2324659	5
I	13125	1	35	1971707725	681805475	453592	71724235	10
F	1325	1075	375	210069795	92135875	525883225	5556502	9
I	11375	9375	3125	151102835	66054335	3005047	52446575	8
I	1075	85	275	1033339275	45075705	242388225	29766975	7
M	1325	11	5125	236718325	907184	616601625	69456275	14
M	15375	13125	3875	3224755625	104042665	6690482	10489315	20
F	13125	10125	4	18653971	752679225	318931875	63786375	12


Datos transversales (Cross-Sectional Data)

Son datos que corresponden al mismo momento o aprox. del mismo tiempo.

Tipos de datos: transversales vs series temporales

Los datos de esta figura ¿Son transversales o corresponden a una serie temporal?

Gráfico 1. Casos de Dengue sin antecedentes de viaje por semana epidemiológica según región. SE 31/2023 a SE 2/2024 (n=22.466). Argentina.




Series de tiempo (Time Series Data)

Son datos recopilados en varios puntos de tiempo (minutos, horas, días, meses, años, etc.).

Estos gráficos ayudan a comprender lo que sucedió en el pasado, identificar tendencias e incluso proyectar niveles futuros.

Visualización de datos: ejemplos comunes

Bar chart




Histogram




Scatter plot




Line chart




Boxplot



Pie chart



Visualización de datos: ejemplos menos comunes



Selección del tipo y formato de gráfico

Objetivo

- Qué preguntas queremos responder
- Qué se espera de los datos
- Qué queremos mostrar
- Qué queremos enfatizar o resaltar
- Quién va a ver el gráfico
- Para qué se va a usar el gráfico
- Estilo que queremos utilizar

Tipos de datos a graficar

- Cuántas variables tenemos que representar
- Qué tipos de variables tenemos que representar
- Tipos de interacción entre las variables
- Si los datos son transversales, temporales, u otros (espaciales...)

Primeros gráficos

Dataset de vinos

type	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	pH	sulphates	alcohol	quality
white	8.4	0.17	0.31	6.7	0.038	29	132	3.1	0.32	10.6	7
white	6	0.18	0.31	1.4	0.036	14	75	3.34	0.58	11.1	8
white	8.6	0.36	0.26	11.1	0.03	43.5	171	3.03	0.49	12	5
white	6.9	0.4	0.17	12.9	0.033	59	186	3.08	0.49	9.4	5
red	6.8	0.785	0	2.4	0.104	14	30	3.52	0.55	10.7	6
red	10.8	0.29	0.42	1.6	0.084	19	27	3.28	0.73	11.9	6
white	7.1	0.21	0.32	2.2	0.037	28	141	3.2	0.57	10	7
white	6.1	0.17	0.21	1.9	0.09	44	130	3.07	0.41	9.7	5
white	9.2	0.28	0.46	3.2	0.058	39	133	3.14	0.58	9.5	5
red	11.5	0.59	0.59	2.6	0.087	13	49	3.18	0.65	11	6

Nuestros primeros gráficos

```
# Importamos bibliotecas
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from matplotlib import ticker # Para agregar separador de miles
import seaborn as sns        # Para graficar histograma

# Carpeta donde se encuentran los archivos
carpeta = "ruta/a/los/archivos/"

# Leemos el dataset
wine = pd.read_csv(carpeta + "wine.csv", sep=";")
```

1. Gráfico de dispersión / scatter plot

```
# Genera el gráfico que relaciona la acidez (no volátil) y el  
# contenido  
# de ácido cítrico de cada vino  
plt.scatter(data=wine, x='fixed acidity', y='citric acid')
```




Gráfico de dispersión / scatter plot

```
fig, ax = plt.subplots() → devuelve una tupla!
```

Fig: contenedor principal de todo el gráfico. Puede contener uno o varios ejes.

Usamos fig para ajustes globales (tamaño, guardado de la imagen, etc.)

Ax: ejes, gráficos dentro de cada figura.


Usamos los atributos de ax para ajustar elementos de cada gráfico: etiquetas, líneas, colores, etc.

Gráfico de dispersión / scatter plot

```
fig, ax = plt.subplots()
plt.rcParams['font.family'] = 'sans-serif'

ax.scatter(data=wine,
           x='fixed acidity',
           y='citric acid',
           s=8,          # Tamaño de los puntos
           color='magenta') # Color de los puntos

ax.set_title('Acidez vs contenido de ácido cítrico')
ax.set_xlabel('Acidez (g/dm3)', fontsize='medium')
ax.set_ylabel('Contenido de ácido cítrico (g/dm3)',
              fontsize='medium')
```



¿De qué tipo son las variables graficadas? ¿Cualitativas o cuantitativas?

Ejercicio — Dataset de árboles de espacios verdes

Consigna Cargar el dataset de árboles de espacios verdes de la ciudad de Buenos Aires.

1) Revisar el conjunto de datos:

- ¿Cuántas variables tiene el dataset? ¿De qué tipo son?
- ¿Cuántas filas tiene?
- Las columnas de tipo categórico: ¿qué valores toman? ¿Con qué frecuencia?
- Las columnas de tipo numérico: ¿qué representan? ¿Cómo se distribuyen los valores?

Ejercicio — Dataset de árboles de espacios verdes

2) Armar un df seleccionando las 30 especies más frecuentes y graficar con scatterplot:

- Altura respecto del diámetro.
- Los ejes long-lat.
- Repetir ambos, diferenciando por color según el origen de la especie.

3) Seleccionar las especies Ceibo, Jacarandá, Palo borracho y Tilo. Graficar altura y diámetro diferenciando por color.


2. Gráfico de globos / Bubble chart

```
fig, ax = plt.subplots()
plt.rcParams['font.family'] = 'sans-serif'

tamanoBurbuja = 5 # Cuánto queremos modificar el tamaño de
cada burbuja

ax.scatter(data=wine, x='fixed acidity',
           y='citric acid', s=wine['residual
sugar']*tamanoBurbuja)

ax.set_title('Relación entre tres variables')
ax.set_xlabel('Acidez (g/dm3)', fontsize='medium')
ax.set_ylabel('Contenido de ácido cítrico (g/dm3)',
              fontsize='medium')
```



¿De qué tipo son las variables graficadas? ¿Cualitativas o cuantitativas?

Scatterplot — características

- Representa al menos dos variables numéricas, una en cada eje.
- Pueden sumarse otras variables mediante el uso del color, tipo o tamaño de los marcadores. Estas otras variables pueden ser numéricas, categóricas, ordinales, etc.
- Puede ser útil para entender la correlación entre variables.
- Puede ser útil para entender la distribución de valores de cada variable.

3. Gráfico de torta / pie chart

Antes de graficar...

```
# Contamos cuántos vinos de cada tipo hay en el dataset
wine['type'].value_counts()
```

```
Out[5]:
type
white      79
red        21
Name: count, dtype: int64
```




type	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	pH	sulphates	alcohol	quality
white	8.4	0.17	0.31	6.7	0.038	29	132	3.1	0.32	10.6	7
white	6	0.18	0.31	1.4	0.036	14	75	3.34	0.58	11.1	8
white	8.6	0.36	0.26	11.1	0.03	43.5	171	3.03	0.49	12	5
white	6.9	0.4	0.17	12.9	0.033	59	186	3.08	0.49	9.4	5
red	6.8	0.785	0	2.4	0.104	14	30	3.52	0.55	10.7	6
red	10.8	0.28	0.42	1.6	0.084	10	27	2.28	0.72	11.6	6

Gráfico de torta

```
fig, ax = plt.subplots()
plt.rcParams['font.family'] = 'sans-serif'
plt.rcParams['font.size'] = 9.0

wine['type'].value_counts().plot(kind='pie',
    ax=ax,
    autopct='%1.1f%%',
    colors=['#66b3ff', '#ff9999'],
    startangle=90,
    shadow=True,
    explode=(0.1, 0),
    legend=False)

ax.set_ylabel('')
ax.set_title('Distribución de Tipos de Vino')
```



¿De qué tipo son las variables graficadas? ¿Cualitativas o cuantitativas?

Gráfico de torta

- Un gráfico de torta es un círculo dividido en porciones que representan partes de un conjunto.
- Los humanos no somos buenos para leer ángulos.

Hagamos un experimento para comprobarlo:

- Tratemos de identificar al grupo más grande.
- Tratemos de ordenar a los grupos del mayoritario al minoritario.




Gráfico de torta

Hagamos un experimento para comprobarlo:

- Tratemos de identificar al grupo más grande.
- Tratemos de ordenar a los grupos del mayoritario al minoritario.




Gráfico de torta

Los dos gráficos fueron contruidos usando los mismos datos, sin embargo encontrar al grupo mayoritario y ordenar los grupos resulta mucho más sencillo observando el gráfico de barras.





Gráfico de torta — características

- Representa proporciones o distribuciones porcentuales de una variable numérica (en el tamaño de las porciones) respecto de una variable categórica (color).
- Puede ser útil para entender la distribución entre las categorías.
- Puede no ser útil si hay muchas categorías, o si hay proporciones similares.

Ejercicio — Dataset de vinos

Consigna Con el dataset de vinos:

- ¿Existe o no alguna relación entre el pH de los vinos (pH) y alguna de las otras variables? Mostrarlo gráficamente y justificar la elección del tipo de gráfico.

Discutir con el resto de la clase:

- ¿Cuál fue su objetivo: Explorar, Explicar, Otro?
- ¿Qué tipos de variables estaban en juego?
- ¿Mejoró alguna característica del gráfico para cumplir con el objetivo?

Dataset CheetahRegion

Anio	regionEste	regionOeste	Ventas
1	59	28	87
2	57	33	90
3	68	42	110
4	91	54	145
5	109	61	170
6	96	58	154
7	110	67	177
8	72	103	175
9	63	120	183
10	65	130	195


Los datos de esta tabla ¿Son transversales o corresponden a una serie temporal?

4. Gráfico de barras

```
fig, ax = plt.subplots()
plt.rcParams['font.family'] = 'sans-serif'

ax.bar(data=cheetahRegion, x='Anio', height='Ventas')


ax.set_title('Ventas de la compañía Cheetah Sports')
ax.set_xlabel('Año', fontsize='medium')
ax.set_ylabel('Ventas (millones de $)', fontsize='medium')
ax.set_xlim(0, 11)
ax.set_ylim(0, 250)
ax.set_xticks(range(1,11,1))      # Muestra todos los ticks del
eje x
ax.set_yticks([])                 # Remueve los ticks del eje y
ax.bar_label(ax.containers[0], fontsize=8) # Agrega etiqueta a
cada barra
```



5. Gráfico de barras agrupadas

```
fig, ax = plt.subplots()
plt.rcParams['font.family'] = 'sans-serif'

cheetahRegion.plot(x='Año',
                  y=['regionEste', 'regionOeste'],
                  kind='bar',
                  label=['Region Este', 'Region Oeste'],
                  ax=ax)
```



6. Gráfico de barras apiladas

```
fig, ax = plt.subplots()

# Grafica la serie regionEste
ax.bar(cheetahRegion['Anio'], cheetahRegion['regionEste'],
      label='Region Este', color="#4A4063")

# Grafica la serie regionOeste (apilada sobre regionEste)
ax.bar(cheetahRegion['Anio'], cheetahRegion['regionOeste'],
      bottom=cheetahRegion['regionEste'],
      label='Region Oeste', color='skyblue')
```




Gráfico de barras — características


- Representa dos variables: una numérica (altura de las barras) y una categórica u ordinal (una barra para cada categoría).
- A veces corresponden a una secuencia temporal.
- Pueden representar además otra variable categórica mediante el uso de colores. Esta nueva variable debería tomar pocos valores (2 o 3) para que el gráfico no se vuelva incomprensible.

7. Gráfico de líneas

```
fig, ax = plt.subplots()
plt.rcParams['font.family'] = 'sans-serif'

ax.plot('Año', 'Ventas', data=cheetahRegion, marker="o")

ax.set_title('Ventas de la compañía Cheetah Sports')
ax.set_xlabel('Año', fontsize='medium')
ax.set_ylabel('Ventas (millones de $)', fontsize='medium')
ax.set_xlim(0, 12)
ax.set_ylim(0, 250)
```



Tipo de gráfico muy
utilizado para series
temporales

8. Gráfico de líneas — múltiples series

```
fig, ax = plt.subplots()
plt.rcParams['font.family'] = 'sans-serif'

# Grafica la serie regionEste
ax.plot('Anio', 'regionEste', data=cheetahRegion,
        marker='.', linestyle='-', linewidth=0.5,
        label='Región Este')

# Grafica la serie regionOeste
ax.plot('Anio', 'regionOeste', data=cheetahRegion,
        marker='.', linestyle='-', linewidth=0.5,
        label='Región Oeste')
```




Gráfico de líneas — características

- Representa dos variables numéricas (x , y) donde para cada x hay como mucho un valor de y . La línea graficada interpola linealmente los valores de (x , y) existentes en la muestra.
- La variable x a veces representa el paso del tiempo.
- Idealmente debe haber bastantes valores distintos de x para que el gráfico cobre sentido.
- Se pueden representar más variables mediante el uso de colores o tipos de línea (llena / punteada / etc.).
- Puede ser útil para entender la relación entre las variables.

Ejercicio — Precios del biodiesel en Argentina

Consigna Datos correspondientes a los precios del biodiesel en distintos períodos en la Argentina (archivo en el campus).

- Representarlos gráficamente.
- Analizar los resultados obtenidos.
- Discutir con el resto de la clase: ¿Cuál fue su objetivo: Explorar, Explicar, Otro? / ¿Qué tipos de variables estaban en juego? / ¿Qué tipo de gráfico decidió utilizar? / ¿Qué resultados obtuvo? / ¿Mejóro alguna característica del gráfico para cumplir con el objetivo?

Periodo	Precio
202312	686,986
202311	520
202310	434,006
202309	361,672
202308	346,000
202307	

Ejercicio — Poseedores de teléfonos inteligentes

Consigna Datos correspondientes a poseedores de teléfonos (archivo en el campus).

- Generar un gráfico para representarlos gráficamente.
- Analizar los resultados obtenidos.
- Discutir con el resto de la clase: ¿Cuál fue su objetivo? / ¿Qué tipos de variables estaban en juego? / ¿Qué tipo de gráfico decidió utilizar? / ¿Qué resultados obtuvo? / ¿Mejoró alguna característica del gráfico?
- Responder Verdadero o Falso y justificar visualmente: "Es más probable que las personas mayores posean un teléfono inteligente a que las personas más jóvenes posean uno."

RangoEtario	Telefono_Inteligente (%)	Telefono_NoInteligente (%)	SinTelefono (%)
18-24	49	46	5
25-34	58	35	7
35-44	44	45	11
45-54	28	58	14
55-64	22	59	19
65+	11	45	44

Ejercicio — Dataset CheetahRegion

Dataset CheetahRegion — ventas de la compañía Cheetah Sports por región y año (ya cargado).

1) Gráfico de barras apiladas:

- Mostrar las ventas totales por año, distinguiendo la contribución de cada región.
- ¿En qué año fue mayor la diferencia entre las dos regiones?

2) Gráfico de líneas:

- Mostrar la evolución de las ventas por región a lo largo del tiempo.
- ¿Qué región creció más entre el año 1 y el año 10?

Anio	regionEste	regionOeste	Ventas
1	59	28	87
2	57	33	90
3	68	42	110
4	91	54	145
5	109	61	170
6	96	58	154
7	110	67	177
8	72	103	175
9	63	120	183
10	65	130	195

Distribución de los Datos

Visualización — Distribución de los Datos

Edades de los atletas olímpicos de USA en los últimos 4 torneos de verano
(Bordes: izquierdo -> mínimo; derecho -> máximo)

FIGURE 5.1 Overlapping Range Bar Chart For Ages Of U.S. Olympic Gymnasts

Male Female Both

Age Range of U.S. Gymnasts in the Four Most Recent Summer Games



- ¿En qué rango de edades hubo participación femenina? ¿Masculina? ¿Ambos?
- ¿Cuántos individuos femeninos de 20 años de edad participaron? ¿Y masculinos?
- ¿Para qué edades podemos afirmar que hubo participación?

Visualización — Distribución de los Datos

Edades de los atletas olímpicos de USA en los últimos 4 torneos de verano
(Bordes: izquierdo -> mínimo; derecho -> máximo)

FIGURE 5.1 Overlapping Range Bar Chart For Ages Of U.S. Olympic Gymnasts



¡No hay información sobre cómo se distribuyen lxs gimnastxs femeninos y masculinos en sus respectivos rangos!

Esta forma de visualizar datos:

- No es intuitiva
- Aumenta la carga cognitiva de la audiencia


Visualización — Distribución de los Datos

Edades de los atletas olímpicos de USA en los últimos 4 torneos de verano

FIGURE 5.2 Frequency Polygon for U.S. Olympic Gymnasts

Age Distribution of U.S. Olympic Gymnasts

Count of Gymnasts



- ¿En qué rango de edad hubo participación femenina? ¿Masculina? ¿Ambos?
- ¿Qué cantidad de individuos de sexo femenino de 20 años participó? ¿Y masculino?
- ¿Para qué edades podemos afirmar que hubo participación?

¡Muestra información sobre la distribución por edades de gimnastxs masculinos y femeninos!

Visualización — Distribución de los Datos

El rol del análisis descriptivo es analizar y visualizar datos para comprender mejor la variación y su impacto.

Distribución de frecuencia de una variable: describe qué valores se observaron y con qué frecuencia esos valores aparecen en dichos datos.

**Distribución
de
frecuencia**

Variable categórica

(etiquetas que no pueden manipularse aritméticamente)

Variable cuantitativa

(valores numéricos que pueden manipularse aritméticamente)

Visualización — Distribución de Datos categóricos

Una distribución de frecuencia (de variables categóricas) es un resumen de datos que muestra el **número (frecuencia)** de observaciones en **cada una de las clases** (no superpuestas), denominadas **bins**.

Compras_gaseosas
Coca-Cola
Sprite
Pepsi
Pepsi
Dr. Pepper
Coca Diet
Coca-Cola

500
compras

Compras_gaseosas	
Coca-Cola	190
Pepsi	130
Coca Diet	80
Dr. Pepper	50
Sprite	50

La distribución de frecuencia resume la información sobre la popularidad de las cinco gaseosas





Gráfico — Distribución de Datos categóricos

```
fig, ax = plt.subplots()
gaseosas['Compras_gaseosas'].value_counts().plot.bar(ax=ax)

ax.set_title('Frecuencia Venta de Gaseosas')
ax.set_xlabel('Marcas de gaseosas')
ax.set_yticks([])
ax.bar_label(ax.containers[0], fontsize=8)
ax.tick_params(axis='x', labelrotation=0)
```



Distribución de Datos categóricos

La distribución de Frecuencia Absoluta muestra la cantidad (recuento) de artículos en cada uno de los bins. A veces nos interesa la proporción o porcentaje de artículos en cada contenedor.

Frecuencia relativa de un bin: fracción o proporción de ítems que pertenecen a ese bin (clase).


`Frecuencia relativa de un bin = Frecuencia absoluta del bin / n`

donde n es la cantidad total de observaciones

Frecuencia porcentual de un bin: frecuencia relativa multiplicada por 100.

Visualización — Distribución de Datos categóricos

Compras_gaseosas
Coca-Cola
Sprite
Pepsi
Pepsi
Dr. Pepper
Coca Diet
Coca-Cola
Coca-Cola



Compras_gaseosas	
Coca-Cola	0.38
Pepsi	0.26
Coca Diet	0.16
Dr. Pepper	0.10
Sprite	0.10

Frecuencia relativa






Gráfico — Distribución de Datos categóricos

```
# Tabla de frecuencias relativas  
gaseosas['Compras_gaseosas'].value_counts(normalize=True)
```

```
Out[16]:  
Compras_gaseosas  
Coca-Cola      0.38  
Pepsi          0.26  
Coca Diet      0.16  
Sprite         0.10  
Dr. Pepper     0.10  
Name: proportion, dtype: float64
```

```
fig, ax = plt.subplots()  
ax =  
gaseosas['Compras_gaseosas'].value_counts(normalize=True).plot.bar()
```



Distribución de Datos categóricos

- La distribución de frecuencia relativa (o porcentual) se puede usar para estimar las probabilidades relativas de diferentes valores para una variable aleatoria.

Ejemplo: Un puesto de comida adquirirá 12.000 gaseosas para un próximo concierto. ¿Cómo dividirían este total entre los distintos tipos?

Si los datos analizados (muestra) son representativos de la población de clientes, se puede usar esta información para determinar los volúmenes apropiados.

Ej. Los datos sugieren que se deberían adquirir $12.000 \times 0,38 =$
4.560 Coca-Colas.



Compras_gaseosas	
Coca-Cola	0.38
Pepsi	0.26
Coca Diet	0.16
Dr. Pepper	0.10
Sprite	0.10

Distribución de Datos continuos

¿Cuál es la dificultad para obtener la distribución de frecuencia en variables continuas?

Por ejemplo la distribución para la variable Peso (continua, asumir 3 decimales):

Solución:


- Cada bin ahora contiene un rango de valores (en vez de 1 solo valor).
- Como antes, los bins no se deben superponer.

Peso (kg)
59,032
78,127
95,900

Distribución de Datos continuos

AgeAtDeath
81
64
88
85
96
101
87
85

700
datos



Edad más frecuente de muerte


La mayoría muere a edades más avanzadas, aunque un pequeño grupo muere a edades tempranas

Distribución de Datos continuos

```
fig, ax = plt.subplots()




sns.histplot(data=ageAtDeath['AgeAtDeath'], bins=17)
```

¿Qué pasa si cambiamos la cantidad de bins? Grafiquen usando los valores comentados en el código.



Distribución de Datos continuos

La cantidad de bins y el ancho de los mismos puede afectar en gran medida la visualización de una distribución.



Distribución de Datos continuos

1. Cantidad de bins

Muchos bins → contienen solo unas pocas observaciones → no captura patrones generalizables (puede parecer irregular y "ruidoso").

Pocos bins → rango de valores muy amplio en mismo bin → no captura con precisión la variación en los datos y solo presenta patrones "borrosos" de alto nivel.

La elección de la cantidad de bins es **subjetiva**, depende del tema y el objetivo del análisis.

Recomendación: utilizar de 5 a 20 bins.

Pocas observaciones → 5 o 6 bins

Muchas observaciones → Más bins.

Distribución de Datos continuos

2. Ancho de bins

Tomar anchos distintos para cada bin puede llevar a decisiones equivocadas.

Recomendación: utilizar bins del mismo ancho.

Distribución de Datos continuos

3. Rango de valores de bins



- Todas las observaciones deberían caer dentro de un bin.
- Los bins no deben superponerse.
- Tener cuidado con los extremos.

Recomendación: utilizar rangos de bins que cumplan con lo anterior.

Distribución de Datos continuos

¿Y si queremos analizar la variabilidad de dos variables?

Sex	AgeAtDeath
Female	81
Female	64
Male	88
Female	85
Female	96
Female	101
Female	87
Male	



Ejercicio — Dataset de propinas

Consigna Datos correspondientes a las propinas de un bar (archivo tips.csv en el campus).

Generar un gráfico para analizar la distribución de la propina en función del:

- Sexo
- Día de la semana

Comentar los resultados obtenidos.

Tarea

Resolver los ejercicios 1 a 12 de la guía de visualización.

Bibliografía

- Camm, Cochran, Fry, Ohlmann. Data Visualization: Exploring and Explaining with Data, 1st edition. Cengage Learning, 2022.

